

RML2016.10a 数据集的分类预测任务研究

基于改进 ResNet 的无线电调制识别

您的姓名

您的机构

2025 年 6 月 3 日

目录

- 1 研究背景与目标
- 2 方法论
- 3 技术创新
- 4 实验结果
- 5 总结与展望

- 无线电调制识别是现代通信系统的重要组成部分
- RML2016.10a 数据集是该领域的经典基准数据集
- 现有方法在低信噪比条件下性能有限
- 需要更鲁棒、高效的调制识别算法

研究目标

- 在 RML2016.10a 数据集上实现高精度调制识别
- 探索多种神经网络架构的性能
- 通过创新技术提升分类准确率
- 超越现有 SOTA 方法的性能指标

- **测试集比例:** 0.2 (与多数论文保持一致)
- **训练集比例:** 0.72
- **验证集比例:** 0.08
- 经过实验对比, 该划分比例能更好地训练神经网络

训练集	验证集	测试集
72%	8%	20%

网络架构对比实验

尝试了多种神经网络架构：

- FCNN - 全连接神经网络
- CNN1D - 一维卷积神经网络
- CNN2D - 二维卷积神经网络
- ResNet - 残差神经网络
- Transformer - 注意力机制网络
- ComplexCNN - 复数卷积神经网络

实验结果：ResNet 效果最佳

创新点一：高斯过程回归去噪

理论基础：

- 噪声主要是加性高斯白噪声
- 每点处信号服从高斯分布且相互独立
- 信号可视作高斯过程

实现方法：

- 根据 I/Q 通道数据和信噪比计算噪声标准差
- 设置自适应的 `length_scale` 参数
- 采用高斯过程回归进行信号去噪

效果：分类准确率显著提升

创新点二：旋转数据增强

灵感来源：

- 观察星座图发现信号的旋转属性
- 借鉴 ULCNN 论文的旋转数据增强思想

实现方法：

- 在训练集上对信号进行旋转变换
- 旋转角度： 90° 、 180° 、 270°
- 扩充训练数据量，增强模型鲁棒性

创新点三：混合神经网络架构

观察发现：

- ComplexCNN 收敛速度快
- 准确率仅次于 ResNet，优于 CNN1D 和 CNN2D

融合策略：

- 将 ResNet 的输入层改为复数层
- 直接对复数信号进行处理
- 得到 ResNet 和 ComplexCNN 的混合架构

优势：结合了两种架构的优点

基线对比

收集了 5 篇相关论文作为 baseline

方法	准确率
Previous SOTA	< 65.38%
本研究 (改进前)	-
本研究 (最终)	65.38%

成功超越了 Previous SOTA 的分类准确率指标!

三次关键改进：

- ① 高斯过程回归去噪 → 显著提升准确率
- ② 旋转数据增强 → 增强模型鲁棒性
- ③ 混合网络架构 → 融合优势特征

最终结果：

- 分类准确率达到 **65.38%**
- 超越现有 SOTA 方法
- 验证了创新技术的有效性

- **系统性对比**: 全面评估了多种神经网络架构
- **创新去噪**: 提出基于高斯过程回归的自适应去噪方法
- **数据增强**: 应用旋转变换增强训练数据
- **架构融合**: 设计 ResNet-ComplexCNN 混合网络
- **性能突破**: 实现了 SOTA 性能的超越

- 探索更多数据增强技术
- 研究注意力机制在调制识别中的应用
- 优化模型复杂度，提升推理效率
- 扩展到更多调制类型和数据集
- 研究实时处理的硬件加速方案

谢谢！

欢迎提问与讨论

联系方式: `your.email@example.com`