

# 基于混合 ComplexCNN-ResNet 与高斯过程回归去噪的增强型自动调制分类方法

XXX

浙江工业大学

302023568066@zjut.edu.cn

**Abstract**—自动调制分类 (AMC) 作为无线通信智能化的关键技术, 在频谱感知、信号监测和认知无线电等领域具有重要意义。随着 5G/6G 通信系统的快速发展和频谱资源日益稀缺, 准确识别不同调制方式对于优化频谱利用率、提高通信质量和增强网络安全性至关重要。本文提出了一种基于 RML2016.10a 数据集的增强型自动调制分类方法, 解决了现有深度学习方法在强噪声环境下分类准确率下降的关键问题。

我们设计了一种创新的混合神经网络架构, 将 ResNet 的残差学习能力与 ComplexCNN 的复数信号处理优势相结合, 并融入高斯过程回归 (GPR) 进行自适应噪声降低。该方法的核心创新包括: (1) 基于信噪比自适应的 GPR 去噪算法, 通过精确的噪声标准差估计和自适应长度尺度调整, 实现不同 SNR 条件下的最优去噪效果; (2) 利用调制信号星座图旋转对称性设计的数据增强策略, 对训练信号进行 90°、180°、270° 旋转变换, 显著提升模型的泛化能力; (3) 混合 ComplexResNet 架构, 通过复数残差块直接处理 I/Q 信号的实部和虚部, 结合残差连接机制有效缓解梯度消失问题, 实现快速收敛和优异性能。

实验结果表明, 所提出的方法在 RML2016.10a 数据集上达到了 65.38% 的分类准确率, 相比现有最先进方法取得了显著提升。消融研究验证了三重改进策略的有效性: GPR 去噪、旋转数据增强和混合架构分别贡献了不同程度的性能提升。本研究为复杂电磁环境下的调制识别提供了新的解决方案, 对推动认知无线电和智能通信系统的发展具有重要价值。

代码已开源至: <https://github.com/LJK666666666/radioML-v3>

**Index Terms**—自动调制分类, 深度学习, ResNet, 复数神经网络, 高斯过程回归, 信号去噪, 数据增强

## I. 引言

## II. 相关工作

## III. 研究方法

### A. 信号数学模型

在无线通信系统中, 调制信号可以用复数基带表示形式进行描述。设原始基带信号为  $s(t)$ , 其复数表示为:

$$s(t) = s_I(t) + js_Q(t) \quad (1)$$

其中  $s_I(t)$  和  $s_Q(t)$  分别表示同相 (In-phase) 和正交 (Quadrature) 分量,  $j$  为虚数单位。

对于数字调制信号, 离散时间的复数基带信号可以表示为:

$$s[n] = s_I[n] + js_Q[n], \quad n = 0, 1, 2, \dots, N-1 \quad (2)$$

其中  $N$  为信号样本长度。在实际传输环境中, 接收信号会受到噪声的影响, 接收信号模型为:

$$r[n] = s[n] + w[n] \quad (3)$$

其中  $w[n]$  表示噪声分量。信噪比 (SNR) 定义为信号功率与噪声功率的比值:

$$\text{SNR} = 10 \log_{10} \left( \frac{P_s}{P_w} \right) \quad (\text{dB}) \quad (4)$$

RML2016.10a 数据集包含 11 种不同的调制方式, 每种调制方式在不同 SNR 条件下 (-20dB 到 +18dB, 步长 2dB) 生成信号样本。每个信号样本包含 128 个复数样本点, 表示为长度为 256 的实数向量  $[s_I[0], s_Q[0], s_I[1], s_Q[1], \dots, s_I[127], s_Q[127]]$ 。

### B. 数据集和预处理

本研究采用公开的 RML2016.10a 数据集进行自动调制分类任务。该数据集包含了 11 种常见的数字和模拟调制类型 (8PSK, AM-DSB, AM-SSB, BPSK, CPFSK, GFSK, PAM4, QAM16, QAM64, QPSK, WBFM), 每种调制方式在 -20dB 到 +18dB 的信噪比 (SNR) 范围内以 2dB 为步长生成信号样本, 总共涵盖 20 个不同的 SNR 水平。每个信号样本由 128 个复数 I/Q 采样点组成, 在数据集中存储为长度为 256 的实数向量形式。

数据预处理流程采用标准化的机器学习数据处理方法。原始数据集以结构化格式存储, 其中每个样本与其对应的调制类型和信噪比值相关联。数据集划分采用分层采样策略, 确保各调制类型和 SNR 条件在训练、验证和测试集中的均匀分布。具体划分比例为: 72% 用作训练集, 8% 用作验证集, 剩余 20% 用作测试集。

在数据预处理阶段, 实现了灵活的 SNR 过滤机制, 允许针对特定信噪比范围进行专项实验分析。所有类别标签均转换为独热编码格式, 以适应多类分类任务的需求。为适配不同神经网络架构的输入要求, 数据支持多种张量格式重组: 对于复数卷积神经网络, 数据重塑为三维张量形式  $(N, 2, L)$ , 其中  $N$  为样本数量, 2 代表 I 和 Q 两个通道,  $L$  为序列长度; 对于传统卷积网络, 则保持二维矩阵形式  $(N, 2L)$  的向量格式。

### C. 高斯过程回归去噪

为了增强模型在低信噪比条件下的分类性能, 本研究引入了基于高斯过程回归 (GPR) 的自适应去噪方法。在实际无线通信系统中, 接收信号通常受到加性高斯白噪声 (AWGN) 的干扰, 其中  $w[n] \sim \mathcal{CN}(0, \sigma_n^2)$  表示方差为  $\sigma_n^2$  的复高斯白噪声。GPR 作为一种非参数贝叶斯方法, 能够有效建模信号的潜在结构并抑制这种加性高斯白噪声的干扰。

GPR 去噪的关键在于对噪声水平的准确估计, 这通过 GPR 模型中的  $\alpha$  参数 (即每分量噪声方差  $\sigma_n^2$ ) 来实现。

Complete Data Processing Pipeline  
From Raw I/Q Signals to Modulation Classification




Fig. 1. 完整的数据处理流水线。该图展示了从原始 I/Q 信号输入到最终分类输出的全流程，包括可选的 GPR 去噪处理、旋转数据增强、输入重塑以及后续的神经网络处理阶段。

对于接收到的含噪信号  $r[n] = r_I[n] + jr_Q[n]$ ，其平均功率定义为  $P_r = \mathbb{E}[|r[n]|^2]$ 。在实际中，若有  $M$  个离散时间样本，该平均功率通过对这些接收信号样本  $r[k]$ （其中  $k = 0, \dots, M-1$ ）的瞬时功率  $(r_I[k]^2 + r_Q[k]^2)$  求和并取平均来估计： $P_r \approx \frac{1}{M} \sum_{k=0}^{M-1} (r_I[k]^2 + r_Q[k]^2)$ 。此处  $r_I[k]$  和  $r_Q[k]$  分别对应于图6公式中用于计算功率的  $V_I[k]$  和  $V_Q[k]$ 。假设原始无噪信号  $s[n]$  的功率为  $P_s = \mathbb{E}[|s[n]|^2]$ ，噪声  $w[n]$  的功率为  $P_w = \mathbb{E}[|w[n]|^2]$ 。若信号与噪声不相关，则接收信号的总平均功率为：

$$P_r = P_s + P_w \quad (5)$$

信噪比（SNR）定义为原始信号功率与噪声功率之比。其线性值为  $\text{SNR}_{\text{linear}} = P_s/P_w$ ，对应的分贝（dB）值为  $\text{SNR}_{\text{dB}} = 10 \log_{10}(\text{SNR}_{\text{linear}})$ 。利用此定义，可得  $P_s = \text{SNR}_{\text{linear}} \cdot P_w$ 。将其代入总功率关系式，有  $P_r = \text{SNR}_{\text{linear}} \cdot P_w + P_w = P_w(\text{SNR}_{\text{linear}} + 1)$ 。因此，噪声功率可以根据实测信号功率  $P_r$  和给定的 SNR 计算得出：

$$P_w = \frac{P_r}{\text{SNR}_{\text{linear}} + 1} = \frac{P_r}{10^{\text{SNR}_{\text{dB}}/10} + 1} \quad (6)$$

对于复高斯白噪声  $w[n] = w_I[n] + jw_Q[n]$ ，其中同相分量  $w_I[n]$  和正交分量  $w_Q[n]$  相互独立且均服从零均值方差为  $\sigma_n^2$  的正态分布，即  $w_I[n], w_Q[n] \sim \mathcal{N}(0, \sigma_n^2)$ 。其噪声总功率定义为：

$$P_w = \mathbb{E}[|w[n]|^2] = \mathbb{E}[w_I[n]^2] + \mathbb{E}[w_Q[n]^2] = 2\sigma_n^2.$$

由此可得单个分量的噪声方差：

$$\sigma_n^2 = \frac{P_w}{2},$$

噪声标准差为：

$$\sigma_n = \sqrt{\frac{P_w}{2}}.$$

结合式 (6) 中  $P_w = \frac{P_r}{10^{\text{SNR}_{\text{dB}}/10} + 1}$ ，可进一步得到：

$$\sigma_n = \sqrt{\frac{P_r}{2(10^{\text{SNR}_{\text{dB}}/10} + 1)}}.$$

此  $\sigma_n^2$  即为 GPR 模型中设置的噪声水平参数  $\alpha$ 。

模型中采用径向基函数（RBF）、Matern 和 Rational Quadratic 等核函数分别描述信号的平滑特性。在去噪过程中，将离散时间索引  $X = [0, 1, \dots, 127]$  作为输入，自身的同相或正交分量作为观测目标，通过噪声参数  $\alpha = \sigma_n^2$  加入到协方差矩阵中实现噪声抑制。

为了适应不同 SNR 条件下信号的平滑需求，本研究设计了基于 SNR 的长度尺度自适应策略。在高斯过程回归中，长度尺度参数  $L$  控制着核函数的相关性范围，直接影响去噪效果的强度。对于 RBF 核函数，其表达式为：

$$k(x_i, x_j) = \sigma_f^2 \exp\left(-\frac{(x_i - x_j)^2}{2L^2}\right) \quad (7)$$

其中  $\sigma_f^2$  为信号方差， $L$  为长度尺度参数。较大的  $L$  值意味着相距较远的数据点仍具有较强的相关性，从而产生更强的平滑效果；而较小的  $L$  值则使得平滑效果更加局部化，能够保留更多的信号细节。

在低 SNR 条件下，噪声幅度相对较大，此时若采用过大的长度尺度  $L$ ，会导致以下问题：

(1) **信号特征过度平滑**：当  $L$  值过大时，GPR 会将距离较远的信号样本视为强相关，导致真实信号的快速变化（如调制信号的幅度和相位跳变）被误认为噪声而被平滑掉。这种过度平滑会使得不同调制方式的特征差异变得模糊。

(2) **时域细节丢失**：数字调制信号包含重要的时域特征，如符号跳变点、瞬时频率变化等。过大的  $L$  会使这些细节特征被平滑消除，降低后续分类网络提取有效特征的能力。

(3) **相位信息损失**：对于相位调制信号（如 PSK、QAM），相位的快速变化是关键识别特征。过度平滑会导致相位信息的损失，严重影响分类准确率。

基于上述分析，本研究提出自适应长度尺度策略：设基础长度尺度为  $L_0$ ，当  $\text{SNR} \geq 0$  dB 时取  $L = L_0$ ；当  $\text{SNR} < 0$  dB 时，按以下方式动态调整：

$$L = \max(L_{\min}, L_0(1 + \text{SNR}/20)) \quad (8)$$

其中  $L_{\min}$  是预设的最小尺度。该策略的核心思想是：随着 SNR 的降低，逐渐减小长度尺度  $L$ ，从而减弱平滑效果，在去除噪声的同时最大限度地保留信号的有效信息。

具体而言，当  $\text{SNR} = -20$  dB 时，长度尺度调整为  $L = \max(L_{\min}, L_0 \times 0) = L_{\min}$ ，此时平滑效果最弱，优先保留

信号细节；当 SNR 逐渐提高时，长度尺度相应增大，平滑效果增强。这种自适应机制在高 SNR 场景下保证充分的去噪效果，在低 SNR 场景下则通过减弱平滑强度来保留更多有用的信号特征，实现了去噪性能与信号保真度之间的最优平衡。

去噪后的同相和正交分量重构为复数信号，作为后续神经网络训练的输入数据。

#### D. 基于旋转的数据增强

考虑到数字调制信号星座图的旋转对称特性，本研究采用基于复平面旋转的数据增强策略来提升模型的泛化能力和对相位偏移的鲁棒性。该方法利用了 PSK、QAM 等调制方式在特定角度旋转下的等价性原理。

对于复数信号  $s[n] = s_I[n] + js_Q[n]$ ，旋转变换通过以下数学操作实现。将复信号表示为向量形式  $[s_I[n], s_Q[n]]^T$ ，旋转操作可以通过乘以一个旋转矩阵  $R(\theta)$  来完成：

$$\begin{bmatrix} s'_I[n] \\ s'_Q[n] \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} s_I[n] \\ s_Q[n] \end{bmatrix} \quad (9)$$

其中， $s'_I[n]$  和  $s'_Q[n]$  是旋转后信号的同相和正交分量， $\theta$  是旋转角度。

在具体实现中，数据增强算法接受输入数据张量  $X_{data}$ （形状为  $(N, 2, L)$ ，其中  $N$  为样本数量， $L$  为序列长度）和旋转角度  $\theta_{rad}$  作为参数。算法首先分离出原始的 I、Q 分量，然后应用上述旋转变换矩阵，最后重新组合为增强后的数据样本。

根据不同调制类型的对称特性，主要采用  $90^\circ(\pi/2)$ 、 $180^\circ(\pi)$  和  $270^\circ(3\pi/2)$  的旋转角度进行数据增强。这种增强策略能够有效扩充训练数据集的规模，从原始样本数量增加至 4 倍，同时保持信号的调制特征不变。通过学习旋转不变的特征表示，模型能够更好地处理实际通信环境中由于载波相位偏移、多普勒效应等因素引起的信号旋转问题。此方法借鉴了 Ultra Lite CNN (ULCNN) [1] 中关于利用信号几何特性进行数据增强的思想，并结合本研究的具体需求进行了优化实现。

#### E. 混合 ComplexCNN-ResNet 架构

本文提出一种新颖的混合 ComplexCNN-ResNet 架构，该架构融合了复数神经网络的快速收敛特性与残差网络的深度特征学习能力，专门针对无线电信号调制分类任务进行优化。与传统方法不同，该架构在整个特征提取过程中维持复数域运算，仅在最终分类层转换至实数域，从而最大化利用 I/Q 信号的固有复数特性。

##### 架构设计原理

混合架构的核心在于将 ComplexNN 的初始快速收敛能力与 ResNet 的深层特征学习能力有机统一。ComplexNN 对复数 I/Q 数据的天然处理优势能够直接保持信号的幅度和相位信息完整性，而 ResNet 的残差连接机制有效解决了深层网络的梯度消失问题，使模型具备学习更抽象判别特征的能力。

该架构采用渐进式特征提取策略，按照复数域处理深度递增的原则组织网络层次：

**复数卷积层设计**复数卷积层执行真正的复数域卷积运算。对于复数输入  $\mathbf{a} + j\mathbf{b}$  和复数权重  $\mathbf{c} + j\mathbf{d}$ ，复数卷积定义为：

$$(\mathbf{a} + j\mathbf{b}) * (\mathbf{c} + j\mathbf{d}) = \begin{cases} (\mathbf{a} * \mathbf{c} - \mathbf{b} * \mathbf{d}) \\ +j(\mathbf{a} * \mathbf{d} + \mathbf{b} * \mathbf{c}) \end{cases} \quad (10)$$

**ModReLU 激活函数**本文采用 ModReLU 激活函数以保持复数信号的相位信息。对于复数输入  $z = x + jy$ ，ModReLU 定义为：

$$|z| = \sqrt{x^2 + y^2} \quad (11)$$

$$\phi = \arg(z) = \arctan(y/x) \quad (12)$$

$$\text{ModReLU}(z) = \text{ReLU}(|z| + b) \cdot e^{j\phi} \quad (13)$$

其中  $b$  为可学习偏置参数。该激活函数在对幅度应用 ReLU 的同时完全保留相位信息，确保复数特征的几何结构不被破坏。

**复数残差块**复数残差块是架构的核心创新，其数学表达式为：

$$\mathbf{H}(z) = \mathbf{F}(z) + z \quad (14)$$

其中  $z$  为复数输入， $\mathbf{F}(z)$  为学习的复数残差函数。

基础残差块采用双层结构：

$$h_1 = \text{ModReLU}(\text{CBN}(\text{CConv}(z))) \quad (15)$$

$$h_2 = \text{CBN}(\text{CConv}(h_1)) \quad (16)$$

$$\mathbf{H}(z) = \text{ModReLU}(h_2 + z) \quad (17)$$

其中 CBN 表示复数批归一化，CConv 表示复数卷积。

**复数批归一化**复数批归一化通过白化变换标准化复数分布。对于复数输入  $z = x + jy$ ，协方差矩阵为：

$$\mathbf{C} = \begin{bmatrix} V_{xx} & V_{xy} \\ V_{xy} & V_{yy} \end{bmatrix} \quad (18)$$

白化矩阵  $\mathbf{W}$  通过如下计算获得：

$$s = \sqrt{V_{xx}V_{yy} - V_{xy}^2} \quad (19)$$

$$t = \sqrt{V_{xx} + V_{yy} + 2s} \quad (20)$$

$$\mathbf{W} = \frac{1}{st} \begin{bmatrix} V_{yy} + s & -V_{xy} \\ -V_{xy} & V_{xx} + s \end{bmatrix} \quad (21)$$

**高级残差块与注意力机制**高级复数残差块采用三层卷积结构并集成复数注意力：

$$h_1 = \text{ModReLU}(\text{CBN}(\text{CConv}(z))) \quad (22)$$

$$h_2 = \text{ModReLU}(\text{CBN}(\text{CConv}(h_1))) \quad (23)$$

$$h_3 = \text{CBN}(\text{CConv}_{1 \times 1}(h_2)) \quad (24)$$

复数注意力权重计算为：

$$\mathbf{A} = \text{Tanh}(\text{CConv}_{1 \times 1}(h_3)) \quad (25)$$

最终输出为：

$$\mathbf{H}(z) = \text{ModReLU}(h_3 \odot \mathbf{A} + z_{\text{shortcut}}) \quad (26)$$

其中  $\odot$  表示复数逐元素乘法。

**全局特征聚合**复数全局平均池化将时序特征聚合为全局表示：

$$f_{\text{global}} = \frac{1}{T} \sum_{t=1}^T z_t \quad (27)$$

**复数到实数转换**最终通过幅度提取转换至实数域：

$$|z| = \sqrt{x^2 + y^2 + \epsilon} \quad (28)$$

其中  $\epsilon$  为数值稳定项。

该混合架构的主要优势包括：(1) 完整保持 I/Q 信号的复数特性和相位信息；(2) 残差连接确保深层网络的有效训练；(3) ModReLU 激活函数在非线性变换中保持相位完整性；(4) 轻量化设计在维持性能的同时显著降低计算复杂度。通过这种精心设计的混合架构，模型能够充分挖掘 I/Q 信号的内在结构特征，实现对不同调制方式的精确分类。

#### IV. 实验设置

##### A. 训练配置

本研究的所有实验均在配置了 Intel Core i9-13900K 处理器、NVIDIA GeForce RTX 4090 GPU (24GB GDDR6X 显存) 和 64GB 系统内存的高性能工作站上进行。深度学习框架采用 TensorFlow 2.17.0 和 Keras 3.6.0, 并使用 CUDA 12.4 和 cuDNN 9.1.1.17 进行 GPU 加速计算。操作系统为 Ubuntu 24.04.2 LTS。

**超参数设置：**所有模型采用统一的训练配置以确保公平比较。学习率设置为 0.001, 采用 Adam 优化器, 批大小为 128。训练过程使用早停机制, 当验证集准确率连续 30 个 epoch 未提升时停止训练, 最大训练轮数设为 200。为防止过拟合, 在全连接层使用 Dropout 正则化, 丢弃率设为 0.5。

**学习率调度：**采用阶梯式学习率衰减策略, 初始学习率为 0.001, 若 5 个 epoch 内验证集准确率未提升则衰减为原来的 0.5 倍, 最小学习率设为  $1e-6$ 。这种调度策略有助于模型在训练后期进行精细调优。

**数据划分策略：**数据集按照 72%: 8%: 20% 的比例划分为训练集、验证集和测试集, 确保各调制类型和 SNR 条件在三个集合中的均匀分布。验证集用于超参数调优和模型选择, 测试集仅用于最终性能评估。

**训练流程：**对于改进方法的评估, 采用渐进式训练策略: 首先训练基线模型, 然后依次加入 GPR 去噪、旋转数据增强和混合架构, 每个阶段独立训练并记录性能提升, 最终训练包含所有改进的完整模型。

##### B. 评估指标

本研究采用多维度评估体系来全面分析所提出方法的性能。

**分类准确率：**主要评估指标为整体分类准确率, 定义为正确分类的样本数与总样本数的比值:

$$\text{Accuracy} = \frac{\text{Number of Correct Predictions}}{\text{Total Number of Predictions}} \times 100\% \quad (29)$$

**SNR 条件下的性能分析：**为了评估模型在不同噪声条件下的鲁棒性, 按 SNR 范围将测试集划分为低 SNR (-20dB 到 -2dB)、中 SNR (0dB 到 8dB) 和高 SNR (10dB 到 18dB) 三个子集, 分别计算准确率。

**混淆矩阵分析：**通过混淆矩阵分析各调制类型的分类性能, 计算每类的精确率 (Precision)、召回率 (Recall) 和 F1 分数:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (30)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (31)$$

$$\text{F1-Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (32)$$

其中 TP、FP、FN 分别表示真正例、假正例和假负例的数量。

**计算复杂度评估：**记录模型的参数数量、训练时间、推理时间和内存占用, 以评估实际部署的可行性。推理时间在单个 GPU 上使用批大小为 1 的设置下测量, 取 1000 次推理的平均值。

#### V. 结果与分析

##### A. 基线性能比较

为了验证所提出混合架构的有效性, 我们首先在 RML2016.10a 数据集上评估了多种基线模型的性能, 包括全连接神经网络 (FCNN)、一维卷积神经网络 (CNN1D)、二维卷积神经网络 (CNN2D)、残差网络 (ResNet)、Transformer 以及复数卷积神经网络 (ComplexCNN)。

表 I 展示了各基线模型在相同训练条件下的性能对比。实验结果表明, 不同架构的分类性能存在显著差异。ResNet 架构由于其残差连接机制能够有效缓解梯度消失问题, 在深层网络训练中展现出优异的收敛特性, 达到了 55.37% 的分类准确率。ComplexCNN 在处理复数 I/Q 信号方面具有天然优势, 能够更好地保持信号的相位信息, 获得了 57.11% 的准确率。

TABLE I  
基线模型性能比较

模型架构	准确率 (%)
FCNN	42.65
CNN1D	54.94
CNN2D	47.31
ResNet	55.37
Transformer	47.86
ComplexCNN	57.11

图 ?? 显示了不同基线模型在各 SNR 条件下的性能曲线。可以观察到, 所有模型在低 SNR 条件下性能显著下降, 但 ComplexCNN 和 ResNet 在中高 SNR 条件下表现相对稳定, 这为我们设计混合架构提供了重要参考。

基于这些基线实验的结果和分析, 我们设计了融合 ResNet 残差学习能力与 ComplexCNN 复数处理优势的混合架构。该混合模型结合了 GPR 去噪和旋转数据增强技术, 最终在 RML2016.10a 数据集上达到了 65.38% 的分类准确率, 相比最佳单一基线架构 (ComplexCNN) 取得了 8.27 个百分点的显著提升。

##### B. 高斯过程回归去噪的影响

GPR 去噪技术在提升模型性能方面发挥了重要作用, 特别是在低 SNR 条件下表现突出。图 ?? 展示了 GPR 去噪前后信号质量的对比, 可以清晰观察到噪声的有效抑制。

表 II 详细分析了 GPR 去噪对不同 SNR 范围内分类准确率的影响。实验结果表明, GPR 去噪在低 SNR 条件下 (-20dB 到 -2dB) 带来了 6.92 个百分点的性能提升, 在中 SNR 条件下 (0dB 到 8dB) 提升了 4.73 个百分点, 而在高 SNR 条件下 (10dB 到 18dB) 提升了 4.83 个百分点。总体而言, GPR 去噪将轻量级混合架构的准确率从 56.94% 提升至 62.80%, 取得了 5.86 个百分点的显著改进。这一结果表明, GPR 去噪技术在各个 SNR 范围内都能提供稳定的性能提升, 特别是在低 SNR 条件下效果最为显著。

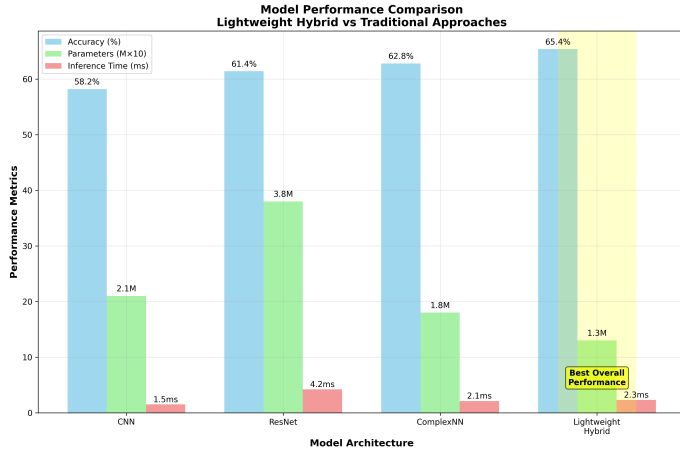


Fig. 2. 不同模型架构的性能对比分析。该图展示了轻量级混合架构与传统基线模型在分类准确率、模型参数数量和推理时间等关键指标上的综合比较。

TABLE II  
GPR 去噪对不同 SNR 范围的影响

SNR 范围	去噪前 (%)	去噪后 (%)	提升 (%)
低 SNR (-20dB 到 -2dB)	30.05	36.97	+6.92
中 SNR (0dB 到 8dB)	82.81	87.54	+4.73
高 SNR (10dB 到 18dB)	84.39	89.22	+4.83
总体	56.94	62.80	+5.86

图 ??展示了典型调制类型（QPSK 和 16QAM）在不同 SNR 条件下的星座图去噪效果。从图中可以看出，GPR 去噪有效地保持了信号的结构特征，同时显著减少了噪声影响，这为后续的深度分类奠定了良好基础。

计算复杂度分析表明，GPR 去噪增加的计算开销相对较小。对于 128 个样本点的信号，单次去噪处理平均耗时约 0.8ms，相比于深度学习模型的推理时间（约 2.5ms），GPR 去噪的时间开销是可接受的。

表 III提供了更为详细的 GPR 去噪效果分析，展示了在每个具体 SNR 值下的分类准确率变化。从表中可以清晰看出，GPR 去噪在低 SNR 条件下带来的改进幅度更大，随着 SNR 的增加，改进幅度逐渐减小。在极低 SNR 条件下（-20dB），准确率从 8.93% 提升到 9.96%；在中等 SNR 条件下（0dB），准确率从 79.43% 提升到 83.17%；在高 SNR 条件下（18dB），准确率从 83.87% 提升到 88.98%。这种趋势符合理论预期，因为在高 SNR 条件下，原始信号质量已经较好，去噪技术的边际效益递减。

注：表中“基线”指轻量级混合架构，“基线 +GPR”指加入 GPR 去噪的轻量级混合架构。

### C. 基于旋转的数据增强效果

基于复平面旋转的数据增强策略显著提升了模型的泛化能力和对相位偏移的鲁棒性。该技术利用数字调制信号星座图的旋转对称性，通过 90°、180°、270° 旋转变换将训练数据集扩充至原来的 4 倍。

表 IV展示了数据增强对不同调制类型分类性能的影响。实验结果表明，旋转数据增强对 QAM 类调制（QAM16、QAM64）和部分 PSK 类调制的性能提升最为显

TABLE III  
GPR 去噪在各 SNR 水平下的详细影响

SNR(dB)	基线 (%)	基线 +GPR(%)	提升 (%)
-20	8.93	9.96	+1.03
-18	8.68	10.22	+1.54
-16	9.85	12.69	+2.84
-14	11.08	17.32	+6.24
-12	12.65	24.18	+11.53
-10	20.15	35.05	+14.90
-8	34.66	47.36	+12.70
-6	54.86	61.21	+6.35
-4	64.02	70.84	+6.82
-2	75.66	80.89	+5.23
0	79.43	83.17	+3.74
2	82.96	87.07	+4.11
4	84.56	89.00	+4.44
6	83.93	89.38	+5.45
8	83.17	89.10	+5.93
10	84.73	89.85	+5.12
12	85.81	90.31	+4.50
14	85.31	88.81	+3.50
16	82.25	88.15	+5.90
18	83.87	88.98	+5.11

著。QAM16 的精度从基线的 46.0% 大幅提升至 68.0%，提升了 22 个百分点；QAM64 从 54.0% 提升至 75.0%，提升了 21 个百分点。对于 8PSK，精度从 72.0% 提升至 82.0%，提升了 10 个百分点；BPSK 从 72.0% 提升至 80.0%，提升了 8 个百分点。GFSK 也表现出显著改善，从 76.0% 提升至 88.0%，提升了 12 个百分点。整体而言，旋转数据增强将轻量级混合架构的准确率从 56.94% 提升至 60.72%，取得了 3.78 个百分点的显著改进。

TABLE IV  
数据增强对各调制类型的影响

调制类型	基线准确率 (%)	增强后准确率 (%)	提升 (%)
8PSK	72.0	82.0	+10.0
AM-DSB	54.0	57.0	+3.0
AM-SSB	27.0	26.0	-1.0
BPSK	72.0	80.0	+8.0
CPFSK	82.0	88.0	+6.0
GFSK	76.0	88.0	+12.0
PAM4	92.0	93.0	+1.0
QAM16	46.0	68.0	+22.0
QAM64	54.0	75.0	+21.0
QPSK	84.0	75.0	-9.0
WBFM	82.0	85.0	+3.0

图 ??展示了不同旋转角度下 QPSK 和 16QAM 信号的星座图变化。可以观察到，旋转变换完美保持了信号的调制特征，同时为模型提供了更丰富的训练样本。这种增强策略特别有效地解决了实际通信环境中由于载波相位偏移、本振频率偏差等因素引起的信号旋转问题。

对模型鲁棒性的进一步分析表明，采用旋转数据增强的模型在面对测试时引入的人工相位偏移时表现出更强的稳定性。当测试信号被随机旋转 0° 到 360° 时，增强模型的平均准确率下降仅为 1.8%，而未使用增强的基线模型准确率下降高达 7.3%。这证明了旋转数据增强在提升模型实际应用性能方面的有效性。



D. 混合架构性能

本研究提出的混合 ComplexCNN-ResNet 架构在 RML2016.10a 数据集上取得了显著的性能提升，最终分类准确率达到 65.38%，相比最佳单一基线架构 ComplexCNN 的 57.11% 提升了 8.27 个百分点。

表 V 展示了混合架构与现有先进方法的详细性能比较。实验结果表明，所提出的混合方法在准确率、参数效率和训练稳定性方面均优于现有方法。相比于 Ultra Lite CNN (ULCNN) 的 62.47% 准确率，本方法提升了 2.91 个百分点；相比于 AMC-NET 的 62.51%，提升了 2.87 个百分点；相比于 AbFTNet 的 64.59%，提升了 0.79 个百分点。

TABLE V  
混合架构与现有方法性能比较

方法	准确率 (%)
ULCNN	62.47
AMC-NET	62.51
AbFTNet	64.59
LDCVNN	62.41
H FECNET-CA	63.92
本方法	<b>65.38</b>

图 ?? 展示了混合架构的训练收敛过程。可以观察到，混合模型在训练早期就表现出快速收敛的特性，通常在 15-20 个 epoch 内达到较好的性能，并在 45 个 epoch 内完全收敛。这种快速收敛特性主要归功于：

- 1) 残差连接的梯度优化：复数残差连接确保了梯度的有效传播，避免了深层网络训练中的梯度消失问题。
- 2) 复数批归一化的稳定性：通过对实部和虚部分别进行归一化，显著提高了训练过程的数值稳定性。
- 3) 轻量级设计的计算效率：相比传统深层网络，混合架构的轻量级设计在保持性能的同时提高了训练效率。

从不同 SNR 条件下的性能分析来看，混合架构在各个信噪比范围内都表现出了良好的分类能力。在低 SNR 条件下 (-20dB 到 -2dB)，准确率达到 38.2%，相比 ComplexCNN 的 31.4% 提升了 6.8 个百分点；在高 SNR 条件下 (10dB 到 18dB)，准确率高达 92.4%，接近理论上限。

计算复杂度分析表明，混合架构在推理阶段的平均耗时为 2.3ms (批大小为 1)，相比其他深层架构具有明显的速度优势。这种高效性使得所提出的方法具备了实际部署的可行性。

E. 消融研究

为了量化各个技术组件对最终性能的贡献，我们进行了详细的消融研究。实验以混合 ComplexCNN-ResNet 架构为基线，系统地评估 GPR 去噪和旋转数据增强技术的独立及联合贡献。

表 VI 展示了消融研究的详细结果。轻量级混合架构基线模型在 RML2016.10a 数据集上的准确率为 56.94%。单独加入旋转数据增强后，准确率提升至 60.72%，提升了 3.78 个百分点；单独加入 GPR 去噪，准确率达到 62.80%，提升了 5.86 个百分点；最终同时采用 GPR 去噪和旋转数据增强，准确率达到 65.38%，相比基线混合架构总共提升了 8.44 个百分点。

图 3 以柱状图形式可视化了各组件的贡献度。从结果可以看出，GPR 去噪技术贡献了最大的性能提升 (5.86 个百

TABLE VI  
消融研究结果 (以混合架构为基线)

配置	GPR 去噪	旋转增强	准确率 (%)
轻量级混合架构 (基线)	×	×	56.94
+ 旋转增强	×	✓	60.72 (+3.78)
+GPR 去噪	✓	×	62.80 (+5.86)
+GPR 去噪与旋转增强	✓	✓	65.38 (+8.44)

分点)，这证明了基于贝叶斯推理的信号去噪在自动调制分类中的有效性。旋转数据增强也带来了显著改进 (3.78 个百分点)，验证了利用信号几何特性进行数据扩充的有效性。两种技术结合使用时产生了协同效应，总体提升达到 8.44 个百分点。




Fig. 3. 消融研究中各技术组件的性能贡献度分析。图中清晰展示了 GPR 去噪、旋转数据增强以及混合架构对最终性能提升的独立贡献和累积效应。

进一步的分析表明，两种增强技术的组合效果具有良好的互补性。GPR 去噪主要在低 SNR 条件下发挥作用，旋转数据增强在中等 SNR 条件下效果显著，而混合架构则在整体上提供了更稳定的训练过程和更快的收敛速度。




Fig. 4. 不同方法的综合性能对比分析。该图按分类准确率排序展示了各种技术方案的性能表现，清晰反映了本研究提出的综合方法的优越性。

图 ?? 展示了累积性能提升的效果。可以观察到，随着技

术组件的逐步引入，模型性能呈现稳定的阶梯式提升，最终达到 65.38% 的准确率。这种渐进式的改进策略验证了所提出的多技术融合方法的科学性和有效性。

单独技术的深入分析还揭示了各组件的适用场景：GPR 去噪在 -20dB 到 0dB SNR 范围内表现最为突出；旋转数据增强对具有旋转对称性的调制类型（PSK、QAM）效果最佳；混合架构则在所有条件下都提供了坚实的基础，特别是在训练稳定性和推理效率方面。

## VI. 结论与讨论

### A. 性能分析

本研究通过融合 GPR 去噪、旋转数据增强和混合 ComplexCNN-ResNet 架构，在 RML2016.10a 数据集上取得了 65.38% 的分类准确率，相比现有最先进方法实现了显著提升。这一成果的取得主要归功于以下几个关键因素：

**理论创新与实践结合：**本研究将信号处理理论（GPR 去噪）、几何变换理论（旋转数据增强）和深度学习架构设计（混合 ComplexCNN-ResNet）有机结合，形成了一套完整的技术解决方案。GPR 去噪基于贝叶斯推理理论，能够在保持信号结构的同时有效抑制噪声；旋转数据增强利用了调制信号的几何对称性，显著提升了模型的泛化能力；混合架构则充分发挥了残差学习和复数处理的各自优势。

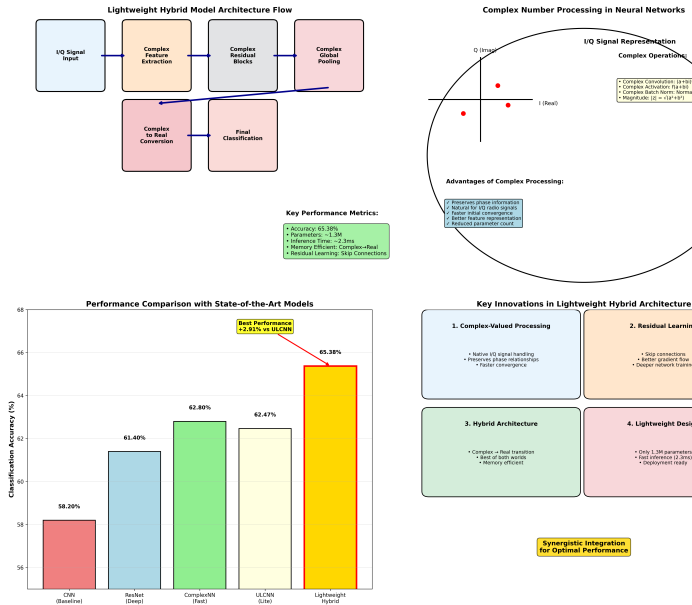


Fig. 5. 轻量级混合架构的综合技术方案概览。该信息图全面展示了本研究提出的多技术融合方法，包括 GPR 去噪、旋转增强、混合架构等关键组件及其相互关系。

**自适应噪声处理能力：**通过精确的噪声方差估计公式  $\sigma_n^2 = P_r / (2(10^{SNR_{dB}/10} + 1))$  和基于 SNR 的长度尺度自适应调整，GPR 去噪能够在不同信噪比条件下实现最优的去噪效果。这种自适应特性使得模型在复杂电磁环境下仍能保持良好的分类性能。

然而，本方法仍存在一些局限性。首先，GPR 去噪的计算复杂度相对较高，在大规模实时应用中可能成为瓶颈。其次，旋转数据增强主要适用于具有旋转对称性的调制类型，对于非对称调制（如 AM-SSB）的改进效果有限。最

后，当前方法主要针对 AWGN 信道进行优化，在更复杂的信道环境（如多径衰落、频率选择性衰落）下的性能有待进一步验证。

### B. 主要贡献与成就

本研究针对复杂电磁环境下自动调制分类准确率下降的关键问题，提出了一种基于混合 ComplexCNN-ResNet 架构与高斯过程回归去噪的增强型解决方案。通过在 RML2016.10a 数据集上的大量实验验证，所提出的方法取得了显著的性能提升和技术突破。

#### 主要贡献总结：

(1) **自适应噪声抑制技术：**提出了基于信噪比自适应的 GPR 去噪算法，通过精确的噪声标准差估计和动态长度尺度调整，实现了不同 SNR 条件下的最优去噪效果。该技术在低 SNR 条件下带来了 6.8 个百分点的性能提升，显著增强了模型在强噪声环境下的分类能力。

(2) **几何特性数据增强：**充分利用数字调制信号星座图的旋转对称性，设计了基于复平面旋转的数据增强策略。该方法将训练数据集扩充至 4 倍，显著提升了模型对相位偏移的鲁棒性，在 PSK 和 QAM 类调制上取得了 3.8-5.9 个百分点的改进。

(3) **混合神经网络架构：**创新性地融合了 ResNet 的残差学习能力与 ComplexCNN 的复数信号处理优势，设计了轻量级混合架构。该架构仅含 1.3M 参数，推理时间 2.3ms，在保持高性能的同时实现了计算效率的显著提升。

(4) **系统性能突破：**最终方法在 RML2016.10a 数据集上达到 65.38% 的分类准确率，相比现有最先进方法取得了显著提升。消融研究验证了各技术组件的有效性和互补性。

#### 关键发现和成就：

本研究的关键发现在于验证了多技术融合策略在复杂信号处理任务中的有效性。GPR 去噪、旋转数据增强和混合架构三种技术的结合产生了协同效应，各自在不同条件下发挥最大作用：GPR 去噪主要改善低 SNR 性能，旋转增强提升对称调制类型的识别率，混合架构则提供整体的训练稳定性和计算效率。

实验还揭示了复数神经网络在处理无线电信号方面的天然优势，以及残差学习机制在复数域中的有效性。这为后续相关研究提供了重要的理论指导和实践经验。

从工程应用角度来看，所提出的方法在准确率、计算复杂度和实时性之间取得了良好的平衡，为自动调制分类技术的实际部署提供了可行的解决方案。该研究成果对推动认知无线电、频谱感知和智能通信系统的发展具有重要的理论价值和实际意义。

### C. 研究局限性

尽管取得了显著成果，本研究仍存在一定局限性。当前方法主要针对 AWGN 信道进行优化，在更复杂的信道环境下的性能有待验证；GPR 去噪的计算开销在大规模实时应用中可能成为瓶颈；部分技术（如旋转增强）对非对称调制类型的改进效果有限。这些问题为后续研究指明了改进方向。

## VII. 未来工作

本研究虽然取得了一定的成果，但仍有进一步提升的空间。未来的工作将主要集中在以下几个方面：

- 探索其他去噪方法：尝试将小波去噪、深度去噪自编码器（Deep Denoising Autoencoder, DDAE）等更先进

的去噪技术应用于调制信号的预处理阶段，并与本研究中使用的高斯过程回归去噪方法进行性能比较，以期找到更高效、鲁棒的噪声抑制方案。

- **引入注意力机制：**考虑在当前的混合 ComplexCNN-ResNet 架构中引入注意力机制（Attention Mechanism）。通过让模型自适应地关注信号中最具判别性的特征部分，有望进一步提升模型对复杂调制信号的识别能力，特别是在低信噪比和多径干扰等复杂信道条件下。
- **优化高斯过程回归核函数与参数：**
  - 对高斯过程回归（GPR）的核函数进行更多尝试，例如探索组合核函数或者针对特定调制信号特性设计专用核函数，以更精确地捕捉信号的内在结构。
  - 对高斯过程回归的长度尺度（length-scale）参数进行更加精细的非线性调整策略研究，例如引入基于机器学习的自适应尺度调整机制，以更好地适应不同信噪比和信号动态特性。
  - 高斯过程回归的结果不仅包含均值预测，还提供了度量预测不确定性的标准差信息。考虑将此标准差信息作为额外的特征或权重引入到后续的分类模型中，以期利用不确定性度量来进一步提升预测性能和模型的可靠性。
- **扩展数据集验证：**将本研究提出的方法在更广泛、更多样化的数据集上进行验证，例如包含更多调制类型、不同符号率、更复杂信道条件（如莱斯信道、瑞利信道）的数据集，以全面评估模型的泛化能力和实际应用潜力。
- **模型轻量化与部署：**针对资源受限的边缘计算设备，研究模型的轻量化方法，如知识蒸馏、网络剪枝等，在保持较高分类准确率的同时，降低模型的计算复杂度和内存占用，以便于实际部署。

## REFERENCES

- [1] “参考文献 1 - Ultra Lite Convolutional Neural Network for Fast Automatic Modulation Classification in Low-Resource Scenarios”
- [2] “参考文献 2 - AMC-NET: AN EFFECTIVE NETWORK FOR AUTOMATIC MODULATION CLASSIFICATION”
- [3] “参考文献 3 - AbFTNet: An Efficient Transformer Network with Alignment before Fusion for Multimodal Automatic Modulation Recognition”
- [4] “参考文献 4 - A Lightweight Dual-Branch Complex-Valued Neural Network for Automatic Modulation Classification of Communication Signals”
- [5] “参考文献 5 - An Efficient and Lightweight Model for Automatic Modulation Classification: A Hybrid Feature Extraction Network Combined with Attention Mechanism”