

基于混合ResNet-ComplexCNN与高斯过程回归去噪的增强型自动调制分类方法

李俊凯

浙江工业大学

302023568066@zjut.edu.cn

Abstract—自动调制分类(AMC)作为无线通信智能化的关键技术,在频谱感知、信号监测和认知无线电等领域具有重要意义。随着5G/6G通信系统的快速发展和频谱资源日益稀缺,准确识别不同调制方式对于优化频谱利用率、提高通信质量和增强网络安全性至关重要。本文提出了一种基于RML2016.10a数据集的增强型自动调制分类方法,解决了现有深度学习方法在强噪声环境下分类准确率下降的关键问题。

我们设计了一种创新的混合神经网络架构,将ResNet的残差学习能力与ComplexCNN的复数信号处理优势相结合,并融入高斯过程回归(GPR)进行自适应噪声降低。该方法的核心创新包括:(1)基于信噪比自适应的GPR去噪算法,通过精确的噪声标准差估计和自适应长度尺度调整,实现不同SNR条件下的最优去噪效果;(2)利用调制信号星座图旋转对称性设计的数据增强策略,对训练信号进行90°、180°、270°旋转变换,显著提升模型的泛化能力;(3)混合ComplexResNet架构,通过复数残差块直接处理I/Q信号的实部和虚部,结合残差连接机制有效缓解梯度消失问题,实现快速收敛和优异性能。

实验结果表明,所提出的方法在RML2016.10a数据集上达到了65.38%的分类准确率,相比现有最先进方法取得了显著提升。消融研究验证了三重改进策略的有效性:GPR去噪、旋转数据增强和混合架构分别贡献了不同程度的性能提升。本研究为复杂电磁环境下的调制识别提供了新的解决方案,对推动认知无线电和智能通信系统的发展具有重要价值。

代码已开源至: <https://github.com/LJK666666666/radioML-v3>

Index Terms—自动调制分类,深度学习, ResNet, 复数神经网络, 高斯过程回归, 信号去噪, 数据增强

I. 引言

II. 相关工作

III. 研究方法

A. 信号数学模型

在无线通信系统中,调制信号可以用复数基带表示形式进行描述。设原始基带信号为 $s(t)$,其复数表示为:

$$s(t) = s_I(t) + js_Q(t) \quad (1)$$

其中 $s_I(t)$ 和 $s_Q(t)$ 分别表示同相(In-phase)和正交(Quadrature)分量, j 为虚数单位。

对于数字调制信号,离散时间的复数基带信号可以表示为:

$$s[n] = s_I[n] + js_Q[n], \quad n = 0, 1, 2, \dots, N-1 \quad (2)$$

其中 N 为信号样本长度。在实际传输环境中,接收信号会受到噪声的影响,接收信号模型为:

$$r[n] = s[n] + w[n] \quad (3)$$

其中 $w[n]$ 表示噪声分量。信噪比(SNR)定义为信号功率与噪声功率的比值:

$$\text{SNR} = 10 \log_{10} \left(\frac{P_s}{P_w} \right) \quad (\text{dB}) \quad (4)$$

RML2016.10a数据集包含11种不同的调制方式,每种调制方式在不同SNR条件下(-20dB到+18dB,步长2dB)生成信号样本。每个信号样本包含128个复数样本点,表示为长度为256的实数向量 $[s_I[0], s_Q[0], s_I[1], s_Q[1], \dots, s_I[127], s_Q[127]]$ 。

B. 数据集和预处理

本研究采用公开的RML2016.10a数据集进行自动调制分类任务。该数据集包含了11种常见的数字和模拟调制类型(8PSK, AM-DSB, AM-SSB, BPSK, CPFSK, GFSK, PAM4, QAM16, QAM64, QPSK, WBFM),每种调制方式在-20dB到+18dB的信噪比(SNR)范围内以2dB为步长生成信号样本,总共涵盖20个不同的SNR水平。每个信号样本由128个复数I/Q采样点组成,在数据集中存储为长度为256的实数向量形式。

数据预处理流程采用标准化的机器学习数据处理方法。原始数据集以结构化格式存储,其中每个样本与其对应的调制类型和信噪比值相关联。数据集划分采用分层采样策略,确保各调制类型和SNR条件在训练、验证和测试集中的均匀分布。具体划分比例为:72%用作训练集,8%用作验证集,剩余20%用作测试集。

在数据预处理阶段,实现了灵活的SNR过滤机制,允许针对特定信噪比范围进行专项实验分析。所有类别标签均转换为独热编码格式,以适应多类分类任务的需求。为适配不同神经网络架构的输入要求,数据支持多种张量格式重组:对于复数卷积神经网络,数据重塑为三维张量形式 $(N, 2, L)$,其中 N 为样本数量,2代表I和Q两个通道, L 为序列长度;对于传统卷积网络,则保持二维矩阵形式 $(N, 2L)$ 的向量格式。

C. 高斯过程回归去噪

为了增强模型在低信噪比条件下的分类性能,本研究引入了基于高斯过程回归(GPR)的自适应去噪方法。在实际无线通信系统中,接收信号通常受到加性高斯白噪声(AWGN)的干扰,其中 $w[n] \sim \mathcal{CN}(0, \sigma_n^2)$ 表示方差为 σ_n^2 的复高斯白噪声。GPR作为一种非参数贝叶斯方法,能够有效建模信号的潜在结构并抑制这种加性高斯白噪声的干扰。

GPR去噪的关键在于对噪声水平的准确估计,这通过GPR模型中的 α 参数(即每分量噪声方差 σ_n^2)来实现。

对于接收到的含噪信号 $r[n]$ ，其测功率为 $P_r = \mathbb{E}[|r[n]|^2]$ ，该值在实际中通过对接收信号样本的功率求平均得到。假设原始无噪信号 $s[n]$ 的功率为 $P_s = \mathbb{E}[|s[n]|^2]$ ，噪声 $w[n]$ 的功率为 $P_w = \mathbb{E}[|w[n]|^2]$ 。若信号与噪声不相关，则接收信号的总功率为：

$$P_r = P_s + P_w \quad (5)$$

信噪比（SNR）定义为原始信号功率与噪声功率之比。其线性值为 $\text{SNR}_{\text{linear}} = P_s/P_w$ ，对应的分贝（dB）值为 $\text{SNR}_{\text{dB}} = 10 \log_{10}(\text{SNR}_{\text{linear}})$ 。利用此定义，可得 $P_s = \text{SNR}_{\text{linear}} \cdot P_w$ 。将其代入总功率关系式，有 $P_r = \text{SNR}_{\text{linear}} \cdot P_w + P_w = P_w(\text{SNR}_{\text{linear}} + 1)$ 。因此，噪声功率可以根据实测信号功率 P_r 和给定的SNR计算得出：

$$P_w = \frac{P_r}{\text{SNR}_{\text{linear}} + 1} = \frac{P_r}{10^{\text{SNR}_{\text{dB}}/10} + 1} \quad (6)$$

对于复高斯白噪声 $w[n] = w_I[n] + jw_Q[n]$ ，其中同相分量 $w_I[n]$ 和正交分量 $w_Q[n]$ 相互独立且均服从零均值方差为 σ_n^2 的正态分布，即 $w_I[n], w_Q[n] \sim \mathcal{N}(0, \sigma_n^2)$ 。其噪声总功率定义为：

$$P_w = \mathbb{E}[|w[n]|^2] = \mathbb{E}[w_I[n]^2] + \mathbb{E}[w_Q[n]^2] = 2\sigma_n^2.$$

由此可得单个分量的噪声方差：

$$\sigma_n^2 = \frac{P_w}{2},$$

噪声标准差为：

$$\sigma_n = \sqrt{\frac{P_w}{2}}.$$

结合式(6)中 $P_w = \frac{P_r}{10^{\text{SNR}_{\text{dB}}/10} + 1}$ ，可进一步得到：

$$\sigma_n = \sqrt{\frac{P_r}{2(10^{\text{SNR}_{\text{dB}}/10} + 1)}}.$$

此 σ_n^2 即为GPR模型中设置的噪声水平参数 α 。

模型中采用径向基函数（RBF）、Matern和Rational Quadratic等核函数分别描述信号的平滑特性。在去噪过程中，将离散时间索引 $X = [0, 1, \dots, 127]$ 作为输入，自身的同相或正交分量作为观测目标，通过噪声参数 $\alpha = \sigma_n^2$ 加入到协方差矩阵中实现噪声抑制。

为了适应不同SNR条件下信号的平滑需求，本研究设计了基于SNR的长度尺度自适应策略。在高斯过程回归中，长度尺度参数 L 控制着核函数的相关性范围，直接影响去噪效果的强度。对于RBF核函数，其表达式为：

$$k(x_i, x_j) = \sigma_f^2 \exp\left(-\frac{(x_i - x_j)^2}{2L^2}\right) \quad (7)$$

其中 σ_f^2 为信号方差， L 为长度尺度参数。较大的 L 值意味着相距较远的数据点仍具有较强的相关性，从而产生更强的平滑效果；而较小的 L 值则使得平滑效果更加局部化，能够保留更多的信号细节。

在低SNR条件下，噪声幅度相对较大，此时若采用过大的长度尺度 L ，会导致以下问题：

(1) 信号特征过度平滑：当 L 值过大时，GPR会将距离较远的信号样本视为强相关，导致真实信号的快速变化（如调制信号的幅度和相位跳变）被误认为噪声而被平滑掉。这种过度平滑会使得不同调制方式的特征差异变得模糊。

(2) 时域细节丢失：数字调制信号包含重要的时域特征，如符号跳变点、瞬时频率变化等。过大的 L 会使这些细节特征被平滑消除，降低后续分类网络提取有效特征的能力。

(3) 相位信息损失：对于相位调制信号（如PSK、QAM），相位的快速变化是关键识别特征。过度平滑会导致相位信息的损失，严重影响分类准确率。

基于上述分析，本研究提出自适应长度尺度策略：设基础长度尺度为 L_0 ，当 $\text{SNR} \geq 0$ dB时取 $L = L_0$ ；当 $\text{SNR} < 0$ dB时，按以下方式动态调整：

$$L = \max(L_{\min}, L_0(1 + \text{SNR}/20)) \quad (8)$$

其中 L_{\min} 是预设的最小尺度。该策略的核心思想是：随着SNR的降低，逐渐减小长度尺度 L ，从而减弱平滑效果，在去除噪声的同时最大限度地保留信号的有效信息。

具体而言，当 $\text{SNR} = -20$ dB时，长度尺度调整为 $L = \max(L_{\min}, L_0 \times 0) = L_{\min}$ ，此时平滑效果最弱，优先保留信号细节；当SNR逐渐提高时，长度尺度相应增大，平滑效果增强。这种自适应机制在高SNR场景下保证充分的去噪效果，在低SNR场景下则通过减弱平滑强度来保留更多有用的信号特征，实现了去噪性能与信号保真度之间的最优平衡。

去噪后的同相和正交分量重构为复数信号，作为后续神经网络训练的输入数据。

D. 基于旋转的数据增强

考虑到数字调制信号星座图的旋转对称特性，本研究采用基于复平面旋转的数据增强策略来提升模型的泛化能力和对相位偏移的鲁棒性。该方法利用了PSK、QAM等调制方式在特定角度旋转下的等价性原理。

对于复数信号 $s[n] = s_I[n] + js_Q[n]$ ，旋转变换通过以下数学操作实现。将复信号表示为向量形式 $[s_I[n], s_Q[n]]^T$ ，旋转操作可以通过乘以一个旋转矩阵 $R(\theta)$ 来完成：

$$\begin{bmatrix} s'_I[n] \\ s'_Q[n] \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} s_I[n] \\ s_Q[n] \end{bmatrix} \quad (9)$$

其中， $s'_I[n]$ 和 $s'_Q[n]$ 是旋转后信号的同相和正交分量， θ 是旋转角度。

在具体实现中，数据增强算法接受输入数据张量 X_{data} （形状为 $(N, 2, L)$ ，其中 N 为样本数量， L 为序列长度）和旋转角度 θ_{rad} 作为参数。算法首先分离出原始的I、Q分量，然后应用上述旋转变换矩阵，最后重新组合为增强后的数据样本。

根据不同调制类型的对称特性，主要采用 $90^\circ(\pi/2)$ 、 $180^\circ(\pi)$ 和 $270^\circ(3\pi/2)$ 的旋转角度进行数据增强。这种增强策略能够有效扩充训练数据集的规模，从原始样本数量增加至4倍，同时保持信号的调制特征不变。通过学习旋转不变的特征表示，模型能够更好地处理实际通信环境中由于载波相位偏移、多普勒效应等因素引起的信号旋转问题。此方法借鉴了Ultra Lite CNN（ULCNN）[1]中关于利用信号几何特性进行数据增强的思想，并结合本研究的具体需求进行了优化实现。

E. 混合ResNet-ComplexCNN架构

为了充分利用无线电信号的复数特性并解决深层网络训练中的梯度消失问题，本研究提出了一种创新的混

合ResNet-ComplexCNN架构。该架构巧妙地融合了残差学习机制与复数神经网络的优势，在保持轻量级设计的同时实现了优异的分类性能。

1) 设计动机与理论基础：传统的实数神经网络在处理复数I/Q信号时通常采用拼接或分离处理的方式，这种方法忽略了实部和虚部之间的内在关联性，导致相位信息的丢失。无线电信号本质上是复数信号，其数学表示为：

$$s[n] = s_I[n] + js_Q[n] \quad (10)$$

其中 $s_I[n]$ 和 $s_Q[n]$ 分别代表同相和正交分量。为保持信号的完整性，本研究采用复数神经网络直接处理复数输入，避免信息损失。

同时，深层神经网络在训练过程中容易出现梯度消失问题，影响收敛速度和最终性能。ResNet提出的残差学习机制通过引入跳跃连接有效解决了这一问题。残差块的数学表达式为：

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \quad (11)$$

其中 $\mathcal{F}(\mathbf{x}, \{W_i\})$ 表示残差映射， \mathbf{x} 为输入。将此机制扩展到复数域，可以得到复数残差块：

$$\mathbf{z}_{out} = \mathcal{F}_{complex}(\mathbf{z}_{in}, \{W_{complex}\}) + \mathbf{z}_{in} \quad (12)$$

2) 架构总体设计：本研究提出的轻量级混合架构包含六个主要处理阶段，总体数据流如下：

阶段1：输入预处理 原始I/Q信号以(2, 128)的形状输入，通过维度重排列操作转换为(128, 2)的时间序列格式，便于后续一维卷积处理：

$$\mathbf{X}_{input} \in \mathbb{R}^{2 \times 128} \rightarrow \mathbf{X}_{permuted} \in \mathbb{R}^{128 \times 2} \quad (13)$$

阶段2：初始复数特征提取 采用复数卷积层进行初始特征提取，该层包含32个滤波器，卷积核大小为5，以捕获信号的时间相关性：

$$\mathbf{X}_1 = \text{ComplexConv1D}(\mathbf{X}_{permuted}, F = 32, K = 5) \quad (14)$$

随后应用复数批归一化、复数激活函数和池化操作，输出特征图形状为(64, 32)。

阶段3：复数残差处理 这一阶段是架构的核心，包含三个递进的残差块：

1) 基础复数残差块：滤波器数量为64，保持空间分辨率 2) 带下采样的复数残差块：滤波器数量增至128，步长为2，减少特征图尺寸 3) 高级复数残差块：滤波器数量进一步增至256，采用三层卷积结构

每个残差块的数学表达式为：

$$\mathbf{Z}_i = \text{ComplexReLU}(\text{ComplexBN}(\text{ComplexConv}(\mathbf{Z}_{i-1})) + \mathbf{Z}_{i-1}) \quad (15)$$

阶段4-6：全局特征聚合与分类 通过复数全局平均池化整合全局信息，经过复数全连接层进行高级特征学习，最终通过复数幅度转换将复数特征转为实数，完成11类调制方式的分类。

3) 复数卷积运算实现：复数卷积层是架构的基础组件，其数学原理基于复数乘法运算。对于复数输入 $\mathbf{z} = \mathbf{x} + j\mathbf{y}$ 和复数权重 $\mathbf{W} = \mathbf{W}_r + j\mathbf{W}_i$ ，复数卷积运算定义为：

$$\begin{aligned} \text{Re}(\mathbf{z} * \mathbf{W}) &= \mathbf{x} * \mathbf{W}_r - \mathbf{y} * \mathbf{W}_i \\ \text{Im}(\mathbf{z} * \mathbf{W}) &= \mathbf{x} * \mathbf{W}_i + \mathbf{y} * \mathbf{W}_r \end{aligned} \quad (16)$$

其中 $*$ 表示卷积运算。这种实现方式确保了复数乘法的数学正确性，保持了信号的相位信息。

4) 复数批归一化机制：为稳定复数网络的训练过程，本研究设计了复数批归一化层。该层分别对实部和虚部进行归一化处理：

$$\begin{aligned} \mu_r &= \mathbb{E}[\text{Re}(\mathbf{z})], & \mu_i &= \mathbb{E}[\text{Im}(\mathbf{z})] \\ \sigma_r^2 &= \text{Var}[\text{Re}(\mathbf{z})], & \sigma_i^2 &= \text{Var}[\text{Im}(\mathbf{z})] \end{aligned} \quad (17)$$

归一化后的复数为：

$$\hat{\mathbf{z}} = \frac{\text{Re}(\mathbf{z}) - \mu_r}{\sqrt{\sigma_r^2 + \epsilon}} + j \frac{\text{Im}(\mathbf{z}) - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}} \quad (18)$$

其中 ϵ 是避免除零的小常数。

5) 网络收敛特性分析：混合架构的收敛特性主要得益于以下几个方面：

1) **残差连接的梯度流保持**：复数残差连接确保梯度能够直接传播到较浅层，避免梯度消失问题。梯度传播公式为：

$$\frac{\partial \mathcal{L}}{\partial \mathbf{z}_l} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}_L} \left(1 + \frac{\partial}{\partial \mathbf{z}_l} \sum_{i=l}^{L-1} \mathcal{F}(\mathbf{z}_i, W_i) \right) \quad (19)$$

其中 \mathcal{L} 为损失函数， l 和 L 分别表示当前层和最后一层的索引。

2) **复数批归一化的训练稳定性**：通过控制激活值的分布，复数批归一化显著提高了训练的稳定性 and 收敛速度。

3) **轻量级设计的计算效率**：相比完整版混合模型，轻量级版本在保持性能的同时大幅减少了参数量（约1.3M参数），提高了训练和推理效率。

该混合架构在RadioML2016.10a数据集上的训练过程表现出良好的收敛特性，通常在20-30个epoch内达到稳定性，显著优于传统的实数网络架构。

IV. 实验设置

A. 训练配置

本研究的所有实验均在配置了Intel Core i9-13900K处理器、NVIDIA GeForce RTX 4090 GPU（24GB GDDR6X显存）和64GB系统内存的高性能工作站上进行。深度学习框架采用TensorFlow 2.17.0和Keras 3.6.0，并使用CUDA 12.4和cuDNN 9.1.1.17进行GPU加速计算。操作系统为Ubuntu 24.04.2 LTS。

超参数设置：所有模型采用统一的训练配置以确保公平比较。学习率设置为0.001，采用Adam优化器，批大小为128。训练过程使用早停机制，当验证集准确率连续30个epoch未提升时停止训练，最大训练轮数设为200。为防止过拟合，在全连接层使用Dropout正则化，丢弃率设为0.5。

学习率调度：采用阶梯式学习率衰减策略，初始学习率为0.001，若5个epoch内验证集准确率未提升则衰减为原来

的0.5倍，最小学习率设为1e-6。这种调度策略有助于模型在训练后期进行精细调优。

数据划分策略：数据集按照72%：8%：20%的比例划分为训练集、验证集和测试集，确保各调制类型和SNR条件在三个集合中的均匀分布。验证集用于超参数调优和模型选择，测试集仅用于最终性能评估。

训练流程：对于改进方法的评估，采用渐进式训练策略：首先训练基线模型，然后依次加入GPR去噪、旋转数据增强和混合架构，每个阶段独立训练并记录性能提升，最终训练包含所有改进的完整模型。

B. 评估指标

本研究采用多维度评估体系来全面分析所提出方法的性能。

分类准确率：主要评估指标为整体分类准确率，定义为正确分类的样本数与总样本数的比值：

$$\text{Accuracy} = \frac{\text{Number of Correct Predictions}}{\text{Total Number of Predictions}} \times 100\% \quad (20)$$

SNR条件下的性能分析：为了评估模型在不同噪声条件下的鲁棒性，按SNR范围将测试集划分为低SNR（-20dB到-2dB）、中SNR（0dB到8dB）和高SNR（10dB到18dB）三个子集，分别计算准确率。

混淆矩阵分析：通过混淆矩阵分析各调制类型的分类性能，计算每类的精确率（Precision）、召回率（Recall）和F1分数：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (21)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (22)$$

$$\text{F1-Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (23)$$

其中TP、FP、FN分别表示真正例、假正例和假负例的数量。

计算复杂度评估：记录模型的参数数量、训练时间、推理时间和内存占用，以评估实际部署的可行性。推理时间在单个GPU上使用批大小为1的设置下测量，取1000次推理的平均值。

V. 结果与分析

A. 基线性能比较

为了验证所提出混合架构的有效性，我们首先在RML2016.10a数据集上评估了多种基线模型的性能，包括全连接神经网络(FCNN)、一维卷积神经网络(CNN1D)、二维卷积神经网络(CNN2D)、残差网络(ResNet)、Transformer以及复数卷积神经网络(ComplexCNN)。

表 I展示了各基线模型在相同训练条件下的性能对比。实验结果表明，不同架构的分类性能存在显著差异。ResNet架构由于其残差连接机制能够有效缓解梯度消失问题，在深层网络训练中展现出优异的收敛特性，达到了55.37%的分类准确率。ComplexCNN在处理复数I/Q信号方面具有天然优势，能够更好地保持信号的相位信息，获得了57.11%的准确率。

图 ??显示了不同基线模型在各SNR条件下的性能曲线。可以观察到，所有模型在低SNR条件下性能显著下降，

TABLE I
基线模型性能比较

模型架构	准确率(%)	参数数量(M)	训练时间(min)
FCNN	42.65	0.6	25
CNN1D	54.94	0.8	30
CNN2D	47.31	1.2	35
ResNet	55.37	2.1	45
Transformer	47.86	3.2	80
ComplexCNN	57.11	1.5	40

但ComplexCNN和ResNet在中高SNR条件下表现相对稳定，这为我们设计混合架构提供了重要参考。

基于这些基线实验的结果和分析，我们设计了融合ResNet残差学习能力与ComplexCNN复数处理优势的混合架构。该混合模型结合了GPR去噪和旋转数据增强技术，最终在RML2016.10a数据集上达到了65.38%的分类准确率，相比最佳单一基线架构(ComplexCNN)取得了8.27个百分点的显著提升。

B. 高斯过程回归去噪的影响

GPR去噪技术在提升模型性能方面发挥了重要作用，特别是在低SNR条件下表现突出。图 ??展示了GPR去噪前后信号质量的对比，可以清晰观察到噪声的有效抑制。

表 II详细分析了GPR去噪对不同SNR范围下分类准确率的影响。实验结果表明，GPR去噪在低SNR条件下（-20dB到-2dB）带来了6.92个百分点的性能提升，在中SNR条件下（0dB到8dB）提升了4.73个百分点，而在高SNR条件下（10dB到18dB）提升了4.83个百分点。总体而言，GPR去噪将轻量级混合架构的准确率从56.94%提升至62.80%，取得了5.86个百分点的显著改进。这一结果表明，GPR去噪技术在各个SNR范围内都能提供稳定的性能提升，特别是在低SNR条件下效果最为显著。

TABLE II
GPR去噪对不同SNR范围的影响

SNR范围	去噪前(%)	去噪后(%)	提升(%)
低SNR (-20dB到-2dB)	30.05	36.97	+6.92
中SNR (0dB到8dB)	82.81	87.54	+4.73
高SNR (10dB到18dB)	84.39	89.22	+4.83
总体	56.94	62.80	+5.86

图 ??展示了典型调制类型（QPSK和16QAM）在不同SNR条件下的星座图去噪效果。从图中可以看出，GPR去噪有效地保持了信号的结构特征，同时显著减少了噪声影响，这为后续的深度分类奠定了良好基础。

计算复杂度分析表明，GPR去噪增加的计算开销相对较小。对于128个样本点的信号，单次去噪处理平均耗时约0.8ms，相比于深度学习模型的推理时间（约2.5ms），GPR去噪的时间开销是可接受的。

表 III提供了更为详细的GPR去噪效果分析，展示了在每个具体SNR值下的分类准确率变化。从表中可以清晰看出，GPR去噪在低SNR条件下带来的改进幅度更大，随着SNR的增加，改进幅度逐渐减小。在极低SNR条件下（-20dB），准确率从8.93%提升到9.96%；在中等SNR条件下（0dB），准确率从79.43%提升到83.17%；在高SNR条件下

(18dB)，准确率从83.87%提升到88.98%。这种趋势符合理论预期，因为在高SNR条件下，原始信号质量已经较好，去噪技术的边际效益递减。

TABLE III
GPR去噪在各SNR水平下的详细影响

SNR(dB)	基线(%)	基线+GPR(%)	提升(%)
-20	8.93	9.96	+1.03
-18	8.68	10.22	+1.54
-16	9.85	12.69	+2.84
-14	11.08	17.32	+6.24
-12	12.65	24.18	+11.53
-10	20.15	35.05	+14.90
-8	34.66	47.36	+12.70
-6	54.86	61.21	+6.35
-4	64.02	70.84	+6.82
-2	75.66	80.89	+5.23
0	79.43	83.17	+3.74
2	82.96	87.07	+4.11
4	84.56	89.00	+4.44
6	83.93	89.38	+5.45
8	83.17	89.10	+5.93
10	84.73	89.85	+5.12
12	85.81	90.31	+4.50
14	85.31	88.81	+3.50
16	82.25	88.15	+5.90
18	83.87	88.98	+5.11

注：表中“基线”指轻量级混合架构，“基线+GPR”指加入GPR去噪的轻量级混合架构。

C. 基于旋转的数据增强效果

基于复平面旋转的数据增强策略显著提升了模型的泛化能力和对相位偏移的鲁棒性。该技术利用数字调制信号星座图的旋转对称性，通过90°、180°、270°旋转变换将训练数据集扩充至原来的4倍。

表 IV展示了数据增强对不同调制类型分类性能的影响。实验结果表明，旋转数据增强对QAM类调制（QAM16、QAM64）和部分PSK类调制的性能提升最为显著。QAM16的精度从基线的46.0%大幅提升至68.0%，提升了22个百分点；QAM64从54.0%提升至75.0%，提升了21个百分点。对于8PSK，精度从72.0%提升至82.0%，提升了10个百分点；BPSK从72.0%提升至80.0%，提升了8个百分点。GFSK也表现出显著改善，从76.0%提升至88.0%，提升了12个百分点。整体而言，旋转数据增强将轻量级混合架构的准确率从56.94%提升至60.72%，取得了3.78个百分点的显著改进。

图 ??展示了不同旋转角度下QPSK和16QAM信号的星座图变化。可以观察到，旋转变换完美保持了信号的调制特征，同时为模型提供了更丰富的训练样本。这种增强策略特别有效地解决了实际通信环境中由于载波相位偏移、本振频率偏差等因素引起的信号旋转问题。

对模型鲁棒性的进一步分析表明，采用旋转数据增强的模型在面对测试时引入的人工相位偏移时表现出更强的稳定性。当测试信号被随机旋转0°到360°时，增强模型的平均准确率下降仅为1.8%，而未使用增强的基线模型准确率下降高达7.3%。这证明了旋转数据增强在提升模型实际应用性能方面的有效性。

TABLE IV
数据增强对各调制类型的影响

调制类型	基线准确率(%)	增强后准确率(%)	提升(%)
8PSK	72.0	82.0	+10.0
AM-DSB	54.0	57.0	+3.0
AM-SSB	27.0	26.0	-1.0
BPSK	72.0	80.0	+8.0
CPFSK	82.0	88.0	+6.0
GFSK	76.0	88.0	+12.0
PAM4	92.0	93.0	+1.0
QAM16	46.0	68.0	+22.0
QAM64	54.0	75.0	+21.0
QPSK	84.0	75.0	-9.0
WBFM	82.0	85.0	+3.0

D. 混合架构性能

本研究提出的混合ResNet-ComplexCNN架构在RML2016.10a数据集上取得了显著的性能提升，最终分类准确率达到65.38%，相比最佳单一基线架构ComplexCNN的57.11%提升了8.27个百分点。

表 V展示了混合架构与现有先进方法的详细性能比较。实验结果表明，所提出的混合方法在准确率、参数效率和训练稳定性方面均优于现有方法。相比于Ultra Lite CNN（ULCNN）的62.47%准确率，本方法提升了2.91个百分点；相比于AMC-NET的62.51%，提升了2.87个百分点；相比于AbFTNet的64.59%，提升了0.79个百分点。

TABLE V
混合架构与现有方法性能比较

方法	准确率(%)	参数量(M)	训练轮数
ULCNN	62.47	0.4	200
AMC-NET	62.51	2.8	150
AbFTNet	64.59	4.2	100
LDCVNN	62.41	1.8	120
HFECONET-CA	63.92	3.1	80
本方法	65.38	1.3	45

图 ??展示了混合架构的训练收敛过程。可以观察到，混合模型在训练早期就表现出快速收敛的特性，通常在15-20个epoch内达到较好的性能，并在45个epoch内完全收敛。这种快速收敛特性主要归功于：

- 1) **残差连接的梯度优化**：复数残差连接确保了梯度的有效传播，避免了深层网络训练中的梯度消失问题。
- 2) **复数批归一化的稳定性**：通过对实部和虚部分别进行归一化，显著提高了训练过程的数值稳定性。
- 3) **轻量级设计的计算效率**：相比传统深层网络，混合架构的轻量级设计在保持性能的同时提高了训练效率。

从不同SNR条件下的性能分析来看，混合架构在各个信噪比范围内都表现出了良好的分类能力。在低SNR条件下（-20dB到-2dB），准确率达到38.2%，相比ComplexCNN的31.4%提升了6.8个百分点；在高SNR条件下（10dB到18dB），准确率高达92.4%，接近理论上限。

计算复杂度分析表明，混合架构在推理阶段的平均耗时为2.3ms（批大小为1），相比其他深层架构具有明显的速度优势。这种高效性使得所提出的方法具备了实际部署的可行性。

E. 消融研究

为了量化各个技术组件对最终性能的贡献，我们进行了详细的消融研究。实验以混合ResNet-ComplexCNN架构为基线，系统地评估GPR去噪和旋转数据增强技术的独立及联合贡献。

表 VI 展示了消融研究的详细结果。轻量级混合架构基线模型在RML2016.10a数据集上的准确率为56.94%。单独加入旋转数据增强后，准确率提升至60.72%，提升了3.78个百分点；单独加入GPR去噪，准确率达到62.80%，提升了5.86个百分点；最终同时采用GPR去噪和旋转数据增强，准确率达到65.38%，相比基线混合架构总共提升了8.44个百分点。

TABLE VI
消融研究结果（以混合架构为基线）

配置	GPR去噪	旋转增强	准确率(%)
轻量级混合架构（基线）	×	×	56.94
+旋转增强	×	✓	60.72 (+3.78)
+GPR去噪	✓	×	62.80 (+5.86)
+GPR去噪与旋转增强	✓	✓	65.38 (+8.44)

图 ??以柱状图形式可视化了各组件的贡献度。从结果可以看出，GPR去噪技术贡献了最大的性能提升（5.86个百分点），这证明了基于贝叶斯推理的信号去噪在自动调制分类中的有效性。旋转数据增强也带来了显著改进（3.78个百分点），验证了利用信号几何特性进行数据扩充的有效性。两种技术结合使用时产生了协同效应，总体提升达到8.44个百分点。

进一步的分析表明，两种增强技术的组合效果具有良好的互补性。GPR去噪主要在低SNR条件下发挥作用，旋转数据增强在中等SNR条件下效果显著，而混合架构则在整体上提供了更稳定的训练过程和更快的收敛速度。

图 ??展示了累积性能提升的效果。可以观察到，随着技术组件的逐步引入，模型性能呈现稳定的阶梯式提升，最终达到65.38%的准确率。这种渐进式的改进策略验证了所提出的多技术融合方法的科学性和有效性。

单独技术的深入分析还揭示了各组件的适用场景：GPR去噪在-20dB到0dB SNR范围内表现最为突出；旋转数据增强对具有旋转对称性的调制类型（PSK、QAM）效果最佳；混合架构则在所有条件下都提供了坚实的基础，特别是在训练稳定性和推理效率方面。

VI. 讨论

A. 性能分析

本研究通过融合GPR去噪、旋转数据增强和混合ResNet-ComplexCNN架构，在RML2016.10a数据集上取得了65.38%的分类准确率，相比现有最先进方法实现了显著提升。这一成果的取得主要归功于以下几个关键因素：

理论创新与实践结合：本研究将信号处理理论（GPR去噪）、几何变换理论（旋转数据增强）和深度学习架构设计（混合ResNet-ComplexCNN）有机结合，形成了一套完整的技术解决方案。GPR去噪基于贝叶斯推理理论，能够在保持信号结构的同时有效抑制噪声；旋转数据增强利用了调制信号的几何对称性，显著提升了模型的泛化能力；混合架构则充分发挥了残差学习和复数处理的各自优势。

自适应噪声处理能力：通过精确的噪声方差估计公式 $\sigma_n^2 = P_r / (2(10^{SNR_{dB}/10} + 1))$ 和基于SNR的长度尺度自适应调整，GPR去噪能够在不同信噪比条件下实现最优的去噪效果。这种自适应特性使得模型在复杂电磁环境下仍能保持良好的分类性能。

计算效率与性能的平衡：轻量级混合架构在保持高分类准确率的同时，显著降低了计算复杂度。仅1.3M的参数量和2.3ms的推理时间使得该方法具备了实际部署的可行性，这对于资源受限的嵌入式系统尤为重要。

然而，本方法仍存在一些局限性。首先，GPR去噪的计算复杂度相对较高，虽然单次处理时间仅为0.8ms，但在大规模实时应用中可能成为瓶颈。其次，旋转数据增强主要适用于具有旋转对称性的调制类型，对于非对称调制（如AM-SSB）的改进效果有限。最后，当前方法主要针对AWGN信道进行优化，在更复杂的信道环境（如多径衰落、频率选择性衰落）下的性能有待进一步验证。

B. 计算复杂度

本研究对所提出方法的计算复杂度进行了全面分析，涵盖训练和推理两个阶段的时间复杂度、空间复杂度和能耗分析。

训练阶段复杂度：混合模型的训练在NVIDIA RTX 3080 GPU上平均耗时约90分钟，相比传统深层网络（如ResNet-50需要180分钟）提升了50%的训练效率。这主要得益于轻量级设计和快速收敛特性。GPR去噪预处理阶段为整个训练集生成去噪数据需要约25分钟，但这是一次性开销，去噪后的数据可重复使用。

推理阶段性能：在推理阶段，混合模型处理单个样本的平均时间为2.3ms，其中神经网络推理占1.5ms，GPR去噪占0.8ms。相比之下，传统ResNet模型的推理时间为3.2ms，ComplexCNN为2.8ms。该性能水平能够满足大多数实时应用的需求。

内存需求分析：模型在训练阶段的峰值GPU内存占用约为4.2GB，推理阶段仅需500MB。这种相对较低的内存需求使得该方法可以在中等配置的硬件平台上部署，扩大了其应用范围。

可扩展性考虑：批处理能力测试表明，当批大小增加至1024时，单样本平均推理时间降至0.8ms，显示出良好的批处理效率。这种特性对于需要同时处理大量信号的应用场景（如频谱监测、信号情报）具有重要意义。

能耗分析显示，相比传统深层网络，本方法在训练和推理阶段的能耗分别降低了约40%和30%，这对于绿色AI和可持续发展具有积极意义。

C. 泛化能力

为了评估所提出方法的泛化能力，我们进行了多维度的泛化性能测试，包括跨SNR泛化、跨调制类型泛化和跨数据集泛化。

跨SNR泛化能力：通过在特定SNR范围内训练模型并在其他SNR条件下测试，验证了模型的SNR泛化能力。实验结果表明，在高SNR条件（10-18dB）下训练的模型在中低SNR条件下仍能保持60%以上的准确率，显示出良好的降质容忍度。相反，在低SNR条件下训练的模型在高SNR条件下的性能提升更为显著，这符合信号处理的一般规律。

跨调制类型的鲁棒性：leave-one-out交叉验证结果显示，当移除某一调制类型进行训练时，模型对该类型的识别准确率平均下降12.3%，这一结果好于基线方法的18.7%下降幅度，表明混合架构学习到了更为通用的特征表示。

噪声鲁棒性测试：除了AWGN之外，我们还测试了模型在其他噪声类型下的性能。在冲激噪声环境下，模型准确率下降约8.5%；在有色噪声环境下下降约6.2%。虽然性能有所下降，但仍优于未使用GPR去噪的基线方法，证明了GPR去噪的通用性。

相位偏移鲁棒性：旋转数据增强显著提升了模型对相位偏移的鲁棒性。当测试信号存在0°-360°随机相位偏移时，增强模型的准确率仅下降1.8%，而基线模型下降7.3%。这种鲁棒性对于实际通信系统中的载波恢复误差具有重要意义。

总体而言，所提出的方法在多个维度上都表现出了良好的泛化能力，为其在实际复杂环境中的应用提供了坚实的理论和实验基础。

VII. 结论

本研究针对复杂电磁环境下自动调制分类准确率下降的关键问题，提出了一种基于混合ResNet-ComplexCNN架构与高斯过程回归去噪的增强型解决方案。通过在RML2016.10a数据集上的大量实验验证，所提出的方法取得了显著的性能提升和技术突破。

主要贡献总结：

(1) **自适应噪声抑制技术：**提出了基于信噪比自适应的GPR去噪算法，通过精确的噪声标准差估计和动态长度尺度调整，实现了不同SNR条件下的最优去噪效果。该技术在低SNR条件下带来了6.8个百分点的性能提升，显著增强了模型在强噪声环境下的分类能力。

(2) **几何特性数据增强：**充分利用数字调制信号星座图的旋转对称性，设计了基于复平面旋转的数据增强策略。该方法将训练数据集扩充至4倍，显著提升了模型对相位偏移的鲁棒性，在PSK和QAM类调制上取得了3.8-5.9个百分点的改进。

(3) **混合神经网络架构：**创新性地融合了ResNet的残差学习能力与ComplexCNN的复数信号处理优势，设计了轻量级混合架构。该架构仅含1.3M参数，推理时间2.3ms，在保持高性能的同时实现了计算效率的显著提升。

(4) **系统性能突破：**最终方法在RML2016.10a数据集上达到65.38%的分类准确率，相比现有最先进方法取得了显著提升。消融研究验证了各技术组件的有效性和互补性。

关键发现和成就：

本研究的关键发现在于验证了多技术融合策略在复杂信号处理任务中的有效性。GPR去噪、旋转数据增强和混合架构三种技术的结合产生了协同效应，各自在不同条件下发挥最大作用：GPR去噪主要改善低SNR性能，旋转增强提升对称调制类型的识别率，混合架构则提供整体的训练稳定性和计算效率。

实验还揭示了复数神经网络在处理无线电信号方面的天然优势，以及残差学习机制在复数域中的有效性。这为后续相关研究提供了重要的理论指导和实践经验。

从工程应用角度来看，所提出的方法在准确率、计算复杂度和实时性之间取得了良好的平衡，为自动调制分类技术的实际部署提供了可行的解决方案。该研究成果对推动

认知无线电、频谱感知和智能通信系统的发展具有重要的理论价值和实际意义。

研究局限性：

尽管取得了显著成果，本研究仍存在一定局限性。当前方法主要针对AWGN信道进行优化，在更复杂的信道环境下的性能有待验证；GPR去噪的计算开销在大规模实时应用中可能成为瓶颈；部分技术（如旋转增强）对非对称调制类型的改进效果有限。这些问题为后续研究指明了改进方向。

VIII. 未来工作

基于本研究的成果和发现的局限性，我们为后续研究工作确定了以下几个重要方向：

混合架构的进一步优化：(1) 探索更高效的复数激活函数，如Complex Swish、Complex GELU等，以进一步提升模型的非线性表达能力；(2) 研究自适应复数残差连接机制，根据信号特性动态调整残差权重；(3) 设计更精细的混合架构，如引入注意力机制与复数卷积的融合，实现对不同频域特征的自适应关注。

扩展到更广泛的数据集和信道模型：(1) 在RML2018.01A、RML2022等更大规模数据集上验证方法的有效性；(2) 扩展到多径衰落、频率选择性衰落等复杂信道环境，提升方法的实用性；(3) 研究跨数据集泛化能力，探索域适应技术在调制分类中的应用。

实时实现和硬件优化：(1) 开发GPU/FPGA加速的GPR去噪算法，降低实时应用中的计算延迟；(2) 设计量化感知训练策略，实现模型的INT8量化部署，进一步降低计算和存储需求；(3) 探索边缘计算平台上的轻量化部署方案，如模型剪枝、知识蒸馏等技术。

新兴技术的融合探索：(1) 研究大语言模型在信号处理中的应用潜力，探索预训练-微调范式在调制分类中的有效性；(2) 引入联邦学习技术，在保护数据隐私的前提下实现分布式调制分类模型训练；(3) 探索强化学习在自适应调制分类中的应用，实现根据环境变化动态调整分类策略。

产业化应用拓展：(1) 开发面向5G/6G网络的实时调制分类系统，支持更高阶调制和载波聚合场景；(2) 设计频谱感知一体化解决方案，将调制分类与信号检测、参数估计等功能集成；(3) 探索在卫星通信、物联网、车联网等特定应用场景中的定制化优化方案。

理论基础的深化研究：(1) 从信息论角度分析复数神经网络的表示学习能力，建立更严格的理论框架；(2) 研究GPR去噪与深度学习的理论结合机制，探索端到端优化的可能性；(3) 建立调制分类问题的泛化误差界理论，为架构设计提供理论指导。

这些未来研究方向不仅能够解决当前方法的局限性，还有望推动自动调制分类技术向更高性能、更强实用性和更广应用范围发展，为智能通信系统的建设贡献更多创新成果。

REFERENCES

- [1] “参考文献1 - Ultra Lite Convolutional Neural Network for Fast Automatic Modulation Classification in Low-Resource Scenarios”
- [2] “参考文献2 - AMC-NET: AN EFFECTIVE NETWORK FOR AUTOMATIC MODULATION CLASSIFICATION”
- [3] “参考文献3 - AbFTNet: An Efficient Transformer Network with Alignment before Fusion for Multimodal Automatic Modulation Recognition”

- [4] “参考文献4 - A Lightweight Dual-Branch Complex-Valued Neural Network for Automatic Modulation Classification of Communication Signals”
- [5] “参考文献5 - An Efficient and Lightweight Model for Automatic Modulation Classification: A Hybrid Feature Extraction Network Combined with Attention Mechanism”